


Théorie de l'information : DS du 24 octobre 2018

*Master Sciences et Technologies, mention Mathématiques ou Informatique,
parcours Cryptologie et Sécurité informatique*

Responsable : Gilles Zémor

Durée : 1h30. Sans document. Les exercices sont indépendants.

– EXERCICE 1.



On tire au hasard avec la loi uniforme un sommet X d'un cube. Puis on choisit aléatoirement un sommet voisin Y de X , uniformément parmi ses trois voisins possibles. Que vaut l'information mutuelle $I(X, Y)$?

– **Solution.** On a : $H(X) = \log_2 8 = 3 = H(Y)$, $H(Y|X) = \log_2 3$, d'où $I(X, Y) = H(X) - H(X|Y) = 3 - \log_2 3 \approx 1.42$ shannons.

– EXERCICE 2. On suppose que A et B sont deux événements d'un même espace probabilisé Ω , tels que $A \cap B = \emptyset$ et $P(A) = P(B) = 1/4$. Soient X et Y les variables aléatoires $\Omega \rightarrow \{0, 1, -1\}$ définies par :

$$X(\omega) = \begin{cases} 1 & \omega \in A \\ -1 & \omega \in B \\ 0 & \text{sinon} \end{cases} \quad \text{et} \quad Y(\omega) = \begin{cases} -1 & \omega \in A \\ 1 & \omega \in B \\ 0 & \text{sinon} \end{cases}$$

- Les variables X et Y sont-elles indépendantes ?
- Montrer que $H(X) = H(Y) = H(X, Y) = I(X, Y)$. Que vaut cette valeur commune ? Que valent $H(X|Y)$ et $H(Y|X)$?
- Soit $Z = XY$. Montrer que $H(X|Z) = H((X, Y)|Z)$. Que vaut cette valeur ?

– **Solution.**

- Non. On a $P(X = 1) = P(A) = 1/4$, de même $P(Y = 1) = P(B) = 1/4$, mais $P(X = 1, Y = 1) = P(A \cap B) = 0 \neq P(X = 1)P(Y = 1)$.

b) On a $P(X = 1) = P(X = -1) = 1/4$ et $P(X = 0) = 1/2$. D'où

$$H(X) = \frac{2}{4} \log_2 4 + \frac{1}{2} \log_2 2 = \frac{3}{2}.$$

Un calcul similaire donne $H(Y) = H(X) = \frac{3}{2}$.

Par ailleurs,

$$P(X = 1, Y = -1) = P(A) = 1/4$$

$$P(X = -1, Y = 1) = P(B) = 1/4$$

$$P(X = 0, Y = 0) = P((A \cup B)^c) = 1/2.$$

Le couple (X, Y) suit donc la même loi $(1/4, 1/4, 1/2)$ que X et Y et $H(X, Y) = H(X) = H(Y)$. Donc $I(X, Y) = H(X) + H(Y) - H(X, Y) = H(X)$. La formule $H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$ donne donc $H(Y|X) = H(X|Y) = 0$.

c) On a :

$$H(X, Z) = H(Z) + H(X|Z)$$

$$H((X, Y), Z) = H(Z) + H((X, Y)|Z)$$

et comme la valeur de Y est entièrement déterminée par celle de X , on a $H(X, Z) = H((X, Y), Z)$. Donc $H(X|Z) = H((X, Y)|Z)$.

La loi de Z est $(1/2, 1/2)$, donc $H(Z) = 1$ et comme Z est entièrement déterminée par X on a $H(X, Z) = H(X)$. Donc

$$H(X|Z) = H(X) - H(Z) = \frac{3}{2} - 1 = \frac{1}{2}.$$

– EXERCICE 3. Soient X et Y deux variables indépendantes, à valeurs entières, la variable X prenant ses valeurs dans un ensemble de n entiers dénoté A , et la variable Y prenant ses valeurs dans un ensemble de n entiers également, dénoté B . Ceci sous-entend que $P(X = a)$ et $P(Y = b)$ sont toutes les deux non nulles pour tout $a \in A$ et $b \in B$. Si on suppose que $H(X + Y) = H(X) + H(Y)$, quel est le cardinal de l'ensemble $A + B = \{a + b, a \in A, b \in B\}$?

– **Solution.** Comme X et Y sont supposées indépendantes, on a $H(X, Y) = H(X) + H(Y) = H(X + Y)$. Donc $H((X, Y)|X + Y) = 0$, ce qui implique qu'il n'y a jamais deux couples (a, b) et (a', b') distincts dont la somme vaut la même valeur, sinon on ne pourrait pas toujours déterminer (X, Y) à partir de $X + Y$. Donc $|A + B| = |A \times B| = |A||B|$.

– EXERCICE 4. Le code $\{10, 00, 11, 110\}$ est-il uniquement déchiffrable ?


– **Solution.** Oui. On peut décomposer une plage de 1 consécutifs suivie d'un 0 , soit $1 \cdots 10$, ainsi : si le nombre de 1 est supérieur ou égal à trois, la plage ne peut que commencer par le symbole 11. Ensuite il reste soit 110 soit 10 suivant la parité de nombre de 1 dans la plage. Une fois tous les 1 traités, il ne reste plus qu'à intercaler les symboles 00 ce qui se fait clairement sans ambiguïté.

– EXERCICE 5.

- a) Soit C un code de Huffman à quatre mots. Quelles sont les possibles distributions des longueurs $\ell_1 \leq \ell_2 \leq \ell_3 \leq \ell_4$ de C ?
- b) Donner un exemple de loi de probabilité $p_1 \geq p_2 \geq p_3 \geq p_4$ pour laquelle toutes les distributions de longueurs ci-dessus correspondent à un code de Huffman pour cette loi.
- c) Caractériser l'ensemble des lois avec cette propriété.

– **Solution.**

- a) Il n'y en n'a que deux possibles, $(2, 2, 2, 2)$ et $(1, 2, 3, 3)$ qui correspondent aux deux arbres binaires saturés à quatre feuilles.



- b) $(p_1, p_2, p_3, p_4) = (\frac{1}{3}, \frac{1}{3}, \frac{1}{6}, \frac{1}{6})$. Il y a deux choix après la première étape de l'algorithme de Huffman, qui mènent aux deux arbres distincts.
- c) Posons $p'_3 = p_3 + p_4$. Pour que les deux choix soient possibles après la première étape, c'est-à-dire associer p_2 et p'_3 ou bien associer p_1 et p_2 , il faut que $p'_3 = p_1$. Il s'agit donc de caractériser les lois (p_1, p_2, p_3, p_4) telles que $p_1 \geq p_2 \geq p_3 \geq p_4$ et telles que $p'_3 = p_1$. Comme $p_1 + p_2 + p'_3 = 1$ on en déduit $p_2 = 1 - 2p_1$, donc, en écrivant $\frac{1}{2}p'_3 \leq p_2 \leq p_1$,

$$\frac{1}{2}p_1 \leq 1 - 2p_1 \leq p_1$$

soit

$$\frac{1}{3} \leq p_1 \leq \frac{2}{5}.$$

On trouve donc l'ensemble de lois :

$$(p_1, p_2, p_3, p_4) = (p_1, 1 - 2p_1, \frac{p_1}{2} + t, \frac{p_1}{2} - t)$$

avec

$$\frac{1}{3} \leq p_1 \leq \frac{2}{5}$$
$$0 \leq t \leq 1 - \frac{5}{2}p_1.$$

– EXERCICE 6. On considère une source $X_1, X_2, \dots, X_k \dots$ constituée de variables indépendantes de même loi. Cette loi est celle d'une variable prenant quatre valeurs avec probabilités $1/2, 1/4, 1/8, 1/8$.

- a) Quelle est la longueur moyenne d'un encodage optimal, en bits, de la suite X_i . Quelle est la particularité de cette longueur moyenne ?
- b) On considère maintenant la suite des bits encodés $b_1, b_2, \dots, b_n \dots$. Évaluer de manière approchée la quantité

$$\frac{H(b_1, b_2, \dots, b_n)}{n}$$

et sa limite quand n tend vers l'infini.

- c) En déduire $H(b_n)$, pour n grand, ainsi que la loi de b_n .

– **Solution.**

- a) $\bar{\ell} = 14/8 = 7/4$. Elle est égale à l'entropie de X_i .
- b) Comme (b_1, \dots, b_n) permet de reconstituer la source, on a $H(b_1, b_2, \dots, b_n) = H(X_1, \dots, X_k)$ où (b_1, b_2, \dots, b_n) encode (X_1, \dots, X_k) . On a $n \approx k\bar{\ell}$, donc

$$\frac{H(b_1, b_2, \dots, b_n)}{n} \approx \frac{H(X_1, \dots, X_k)}{k\bar{\ell}}.$$

Comme les X_i sont indépendantes on a $H(X_1, \dots, X_k) = kH(X_1)$, et comme $\bar{\ell} = H(X_1)$ on en déduit :

$$\frac{H(b_1, b_2, \dots, b_n)}{n} \approx 1.$$

- c) Comme $H(b_1, b_2, \dots, b_n) \leq H(b_1) + \dots + H(b_n)$ et que, les variables b_i étant binaires, $H(b_i) \leq 1$, on déduit de la question précédente qu'on doit avoir, pour n grand $H(b_n) \approx 1$. La loi de b_n ne peut donc que tendre vers la loi uniforme $(1/2, 1/2)$.