

Théorie de l'information, MHT 813 : Examen du 24
avril 2009

*Master Sciences et Technologies, mention Mathématiques ou Informatique,
spécialité Cryptologie et Sécurité informatique*

Responsable : Gilles Zémor

Durée : 3h. Sans document. Les exercices sont indépendants.

– EXERCICE 1. Quels sont les arbres qui sont associés à un code de Huffman binaire ?

– EXERCICE 2. On prend le n -uplet ordonné $(1, 2, \dots, n)$ et on le perturbe aléatoirement en tirant un numéro au hasard et en le réinsérant au hasard dans la suite. Par exemple, pour $n = 10$, on produit $(1, 2, 3, 7, 4, 5, 6, 8, 9, 10)$ en retirant 7 de sa place initiale entre 6 et 8 et en l'insérant entre 3 et 4.

Quelle est l'entropie du n -uplet résultant ?

– **Solution.** Soit X la variable aléatoire décrivant le n -uplet produit par la procédure. Il s'agit de décrire l'ensemble N des n -uplets perturbés possibles, de trouver la loi de X , i.e. la valeur de $p_x = P(X = x)$ pour tout $x \in N$, puis d'appliquer la formule $H(X) = \sum_x p_x \log 1/p_x$.

La perturbation consiste à choisir un couple (i, j) d'entiers entre 1 et n , où i décrit le numéro tiré au hasard et j décrit l'emplacement où le numéro est remplacé. Par exemple pour $n = 5$, le choix $(i, j) = (2, 1)$ produit le 5-uplet $(2, 1, 3, 4, 5)$: le choix $(i, j) = (5, 3)$ produit le 5-uplet $(1, 2, 5, 3, 4)$, et $(1, 5)$ donne $(2, 3, 4, 5, 1)$. Le choix de (i, j) est uniforme parmi les n^2 choix possibles.

Il faut réaliser que

- tous les choix (i, i) produisent le même n -uplet $(1, 2, \dots, n)$.
- les choix $(i, i + 1)$ et $(i + 1, i)$ produisent le même n -uplet.
- n'importe quel autre choix (i, j) produit un n -uplet unique.


On en déduit que

- un n -uplet apparaît avec probabilité $n/n^2 = 1/n$,
- $n - 1$ n -uplets apparaissent avec probabilité $2/n^2$,
- $n^2 - n - 2(n - 1) = (n - 1)(n - 2)$ n -uplets apparaissent avec probabilité $1/n^2$.

Donc l'entropie du n -uple résultant vaut :

$$\begin{aligned} H(X) &= \frac{1}{n} \log_2 n + (n-1) \frac{2}{n^2} \log_2 \frac{n^2}{2} + (n-1)(n-2) \frac{1}{n^2} \log_2 n^2 \\ &= \left(2 - \frac{1}{n}\right) \log_2 n - \frac{2}{n} + \frac{2}{n^2}. \end{aligned}$$

– EXERCICE 3. On considère le canal discret sans mémoire :




où les probabilités de transition sont données par

$$\begin{aligned} P(Y = 1|X = 0) &= P(Y = 1|X = 1) = P(Y = 0|X = 2) = p \\ P(Y = 0|X = 0) &= P(Y = 0|X = 1) = P(Y = 1|X = 2) = 1 - p \end{aligned}$$

pour un certain paramètre p . Calculer la capacité de ce canal.

– EXERCICE 4. On considère le canal discret sans mémoire :



où les probabilités de transition sont données par

$$\begin{aligned} P(Y = 1|X = 0) &= p & P(Y = 0|X = 0) &= 1 - p \\ P(Y = 0|X = 1) &= p & P(Y = 1|X = 1) &= 1 - p \\ P(Y = 1|X = 2) &= p & P(Y = 0|X = 2) &= 1 - p \\ P(Y = 0|X = 3) &= p & P(Y = 1|X = 3) &= 1 - p \end{aligned}$$

pour un certain paramètre p .

- a) Calculer, en fonction de p , la capacité de ce canal.
- b) En déduire, dans le cas où la loi de X est uniforme, la valeur de $H(X|Y)$.

– EXERCICE 5. Soit C un code linéaire binaire défini par la matrice de parité \mathbf{H} suivante :

$$\mathbf{H} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 & 1 & 1 & 0 & 0 & 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 & 0 & 1 & 0 & 1 & 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}.$$

- a) Quels sont les paramètres $[n, k, d]$ (longueur, dimension, distance minimale) de ce code ?
- b) Démontrer qu'un quelconque vecteur de $\{0, 1\}^{16}$ de poids 3 se transforme de manière unique en un mot de code de poids 4 en changeant un «0» en un «1». En déduire le nombre de mots de poids 4 du code C .
- c) Par une démarche analogue, trouver le nombre de mots de poids 6 de ce code.
- d) Montrer que n'importe quel vecteur de $\{0, 1\}^{16}$ est à distance de Hamming au plus 2 d'un mot de C .
- e) Combien y a-t-il de vecteurs de $\{0, 1\}^{16}$ qui ne sont ni des mots de code ni à distance de Hamming 1 d'un mot de C ?
- f) Soit \mathbf{x} un vecteur de $\{0, 1\}^{16}$ qui n'est ni un mot de C , ni à distance de Hamming 1 d'un mot de C . Montrer qu'il existe 8 mots de C à distance de Hamming 2 de \mathbf{x} .
- g) Quels sont les paramètres du code dual C^\perp de C ?
- h) On reçoit le vecteur suivant avec cinq coordonnées effacées :

$$[????01011101110?].$$

Montrer que le mot du code C coïncidant avec les coordonnées non effacées est unique et le trouver.

- i) On efface aléatoirement et avec une loi uniforme quatre coordonnées d'un mot \mathbf{c} du code C . Calculer la probabilité qu'il soit possible de décoder et de retrouver \mathbf{c} sans ambiguïté.
- j) Montrer que le code C peut corriger simultanément une erreur et un effacement dans n'importe quelle paire $\{i, j\}$ de positions.
- k) Soit σ la fonction syndrome associée à \mathbf{H} ,

$$\begin{aligned} \{0, 1\}^{16} &\longrightarrow \{0, 1\}^5 \\ \mathbf{x} &\mapsto \mathbf{H}^t \mathbf{x}. \end{aligned}$$

Soit $\mathbf{x} = [x_1 \dots x_{16}]$ un vecteur aléatoire uniforme de $\{0, 1\}^{16}$. Quel est le nombre minimum de coordonnées x_i qu'il faut connaître pour avoir un bit d'information (un shannon) sur la valeur du syndrome $\sigma(\mathbf{x})$? Trouver un ensemble minimal de coordonnées x_i dont la connaissance procure deux bits d'information sur la valeur de $\sigma(\mathbf{x})$.

– **Solution.**

- a) $[16, 11, 4]$.
- b) un mot de poids 3 a pour syndrome la somme de trois colonnes de \mathbf{H} : le syndrome a donc un 1 (somme de trois 1) en dernière position. On en déduit qu'il s'agit d'une colonne de \mathbf{H} . Il suffit de modifier la coordonnée correspondante du mot de poids 3 pour obtenir un mot de code. Cette coordonnée est forcément une coordonnée qui passe de «0» à «1» sinon on obtiendrait un mot de poids 2 or $d = 4$.
On en déduit que le nombre de mots de poids 4 égale $\frac{1}{4} \binom{16}{3} = 140$.
- c) De même que précédemment, un mot de poids 5 est exactement à distance 1 d'un mot de code. Si on enlève tous les 140×12 mots de poids 5 qui sont à distance 1 d'un mot de code de poids 4, il reste $\binom{16}{5} - 140 \cdot 12 = 2688$ mots de poids 5 qui sont tous à distance 1 d'un mot de code de poids 6. Il y a donc $2688/6 = 448$ mots de code de poids 6.
- d) Il suffit de voir que n'importe quel vecteur non nul s de $\{0, 1\}^5$ est somme d'au plus 2 colonnes de \mathbf{H} . Ceci est manifestement le cas, si le dernier bit de s est «1», c'est déjà une colonne de \mathbf{H} , sinon on lui ajoute la dernière colonne de \mathbf{H} et on trouve une colonne de \mathbf{H} .
- e) Comme $d = 4$, les boules de rayon 1 centrées autour des mots de code sont disjointes. Leur réunion contient $2^{11}(1 + 16)$ mots. La réponse est donc $2^{16} - 2^{15} - 2^{11} = 2^{15} - 2^{11} = 30720$.
- f) Un mot qui n'est ni un mot de code ni à distance 1 d'un mot de code est à distance 2 d'un mot de code et a pour syndrome s un vecteur de $\{0, 1\}^5$ qui se termine par un 0. La modification d'une coordonnée quelconque donne un syndrome qui se termine par un 1 : un tel syndrome est une colonne de \mathbf{H} qui détermine donc de manière unique la deuxième coordonnée à modifier pour obtenir un mot de code. Il y a 16 manières de procéder ainsi, mais modifier la coordonnée i puis la coordonnée j donne le même mot que si l'on modifie la coordonnée j puis la coordonnée i . On tombe donc sur $16/2 = 8$ mots de code possibles.
- g) $[16, 5, 8]$.
- h) $[0011010111011101]$.
- i) Il s'agit de la probabilité de ne pas tomber sur le support d'un mot de code de

poids 4, c'est-à-dire d'après la question b)

$$1 - \frac{140}{\binom{16}{4}} = \frac{12}{13}.$$

- j) Le code raccourci, c'est-à-dire déduit de C en «oubliant» une coordonnée est manifestement un code linéaire de distance minimale $4 - 1 = 3$. Le code raccourci où on a oublié la coordonnée effacée peut donc corriger une erreur. Une fois l'erreur corrigée on peut corriger l'effacement sans ambiguïté.
- k) Il faut intercepter le support d'un mot du code engendré par les lignes de \mathbf{H} , soit au minimum 8 coordonnées x_i . Si on veut deux bits d'information il faut intercepter la réunion du support de deux mots de code non nuls, soit au minimum 12 symboles. Par exemple tous les x_i sauf x_3, x_4, x_{15}, x_{16} .