

Introduction à la virologie informatique: principes, attaques et défenses

Master 2 CSI - Université de Bordeaux 1

Renaud Tabary: renaud.tabary@labri.fr

12 novembre 2009

Plan

1 Introduction

■ Introduction

■ Objectif du cours

2 Première génération : les virus de boot

3 Deuxième génération : les infecteurs de fichier

4 Troisième génération : Chiffrement et polymorphisme

5 Conclusion

Introduction

Definition

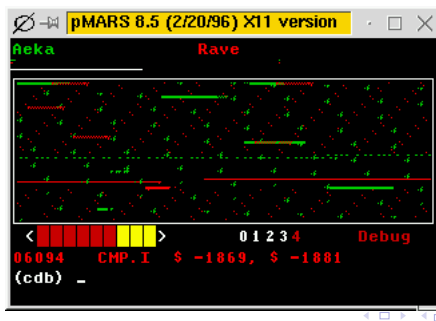
"A virus is a program that is able to infect other programs by modifying them to include a possibly evolved copy of itself."

F.Cohen

- Virus !=malware
- Nous ne **parlerons pas** des vers (trivial)
- Programmes souvent écrits en assembleur (entre 10 lignes et 20000 lignes de code)
- Grande variété de virus :
 - Différentes cibles
 - Différentes charges malicieuses
 - Différents vecteurs de propagations

Corewar

- Un exemple simple
 - Machine virtuelle minimaliste
 - Deux programmes s'affrontent pour *coloniser* la mémoire
 - Le code vit dans la mémoire
- Exemple : corewar



Plan

1 Introduction

■ Introduction

■ Objectif du cours

2 Première génération : les virus de boot

3 Deuxième génération : les infecteurs de fichier

4 Troisième génération : Chiffrement et polymorphisme

5 Conclusion

Pourquoi les étudier ?

- C'est la plus ancienne nuisance informatique
- La **quasi totalité des techniques** des rootkits, vers, trojan et shellcodes **sont issues des virus**
- Un peu plus que de simples format c :
 - Théorie des langages
 - Programmation système
 - Reverse engineering et obfuscation
 - et bien d'autres ...
- Le problème de détection d'un virus est **indécidable**
 - Preuve de F.Cohen basée sur l'arrêt d'une machine de Turing

Pourquoi les étudier ? (2)

Parce qu'ils sont dangereux !

- Remet en jeu l'**intégrité** et la disponibilité du Système Informatique :
 - Suppression de fichiers
 - Backdoors
 - Charge réseau (Netsky)
 - Ransomwares (Gpcode)
- Parfois la **confidentialité** :
 - Vols de mots de passe (jeux en ligne, banque en ligne, etc.)
- Augmentation du nombre de postes connectés et de médias amovibles

Pourquoi les étudier ? (3)

Situation actuelle :

- Marché éclaté entre plus de 20 marques (3 leaders : McAfee, Symantec et Trend Micro)
- Marché en progression (+12,5% en 2008)
- Collaboration entre les différents éditeurs
- Plus de 100 nouvelles détections par jour
- ... et toujours **pas d'antivirus parfait** (cf. Vigard)

Objectifs de ce cours

- Culture générale du spécialiste en sécurité
- Effacer les idées préconçues
- Tracer un historique rapide de l'évolution de la virologie informatique
 - Un bon aperçu du monde de la sécurité informatique
- Introduction aux technique d'infection et de mutation de code
 - Polymorphisme, métamorphisme, chiffrement de code, anti-émulation
 - Se retrouvent dans tous les malwares actuels
- Appréhender les techniques de détection de virus
 - Signature, émulation, heuristique, code normalization, détection comportementale

Contenu du cours

- Historique de la virologie informatique
 - du point de vue de l'attaquant
 - du point de vue du défenseur
- Quelques notions théoriques
 - Théorie des langages, Chomsky hierarchy
 - Il existe des approches très formelles de la virologie que nous n'aborderons pas (cf. Fillol)
- Revue des principales techniques d'obfuscation
 - chiffrement du code, polymorphisme, métamorphisme, anti-*
- TP sur machine virtuelle Windows
 - écriture d'une routine de chiffrement pour un virus existant
 - écriture de règles de polymorphisme
 - test de détection sur un AV récent

Plan

1 Introduction

2 Première génération : les virus de boot

- Méthode d'infection
- Actualité
- Détection

3 Deuxième génération : les infecteurs de fichier

4 Troisième génération : Chiffrement et polymorphisme

5 Conclusion

Le premier virus informatique

- Les virus de boot sont les 1er virus informatique qui se sont propagés
- En 1986 : le virus Brain
- Avantage : indépendant de l'O.S (surtout à l'époque !)
- Démarrage du virus avant l'O.S

Le virus Brain

```

PC Tools Deluxe 84.22
Disk View/Edit Service
Path=A:
Absolute sector 0000000, System BOOT

Displacement      Hex codes
0000(0000)  FA E9 4A 01 34 12 00 07 14 00 01 00 00 00 00 20
0016(0010)  20 20 20 20 20 20 57 65 6C 63 6F 6D 65 20 74 6F
0032(0020)  20 74 68 65 20 44 75 6E 67 65 6F 6E 20 20 20 20
0048(0030)  20 20 20 20 20 20 20 20 20 20 20 20 20 20 20 20
0064(0040)  20 20 20 20 20 20 20 20 20 20 20 20 20 20 20 20
0080(0050)  20 28 63 23 20 31 39 38 36 20 42 61 73 69 74 20
0096(0060)  26 20 41 6D 6A 61 64 20 28 70 76 74 29 20 4C 74
0112(0070)  64 2E 20 20 20 20 20 20 20 20 20 20 20 20 20 20
0128(0080)  20 42 52 41 49 4E 20 43 4F 4D 50 55 54 45 52 20
0144(0090)  53 45 52 56 49 43 45 53 2E 2E 37 33 30 20 4E 49
0160(00A0)  5A 41 4D 20 42 4C 4F 43 4B 20 41 4C 4C 41 4D 41
0176(00B0)  20 49 51 42 41 4C 20 54 4F 57 4E 20 20 20 20 20
0192(00C0)  20 20 20 20 20 20 20 20 20 20 20 4C 41 48 4F 52
0208(00D0)  45 2D 50 41 4B 49 53 54 41 4E 2E 2E 50 48 4F 4E
0224(00E0)  45 2D 3A 34 33 30 37 39 31 2C 34 34 33 32 34 38
0240(00F0)  2C 32 38 30 35 33 30 2E 20 20 20 20 20 20 20 20

ASCII value
-0304; 0 0
Welcome to
the Dungeon

(c) 1986 Basit
& Amjad (pvt) Lt
d.
BRAIN COMPUTER
SERVICES..730 NI
2AM BLOCK ALLAMA
IQBAL TOWN
LAHORE
E-PAKISTAN..PHON
E :430791,443248
,280530.

Home=begin of file/disk End=end of file/disk
ESC=Exit PgDn=forward PgUp=back F2=chg sector num F3=edit F4=get name

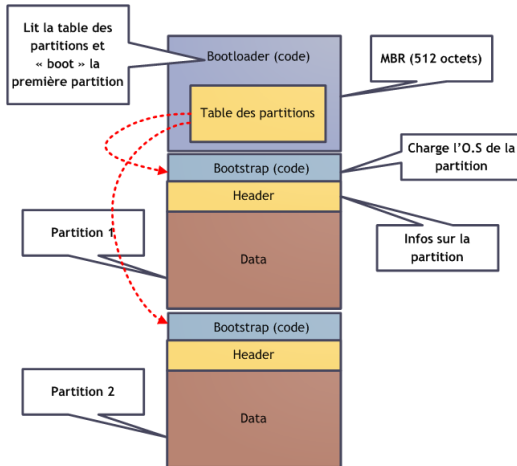
```

FIGURE: Le virus brain

Fonctionnement

- Il n'est pas possible de charger l'O.S depuis la ROM
- Au démarrage du PC, le premier secteur du disque dur (le MBR) est chargé en mémoire
- Le MBR contient un *bootstrap loader* qui charge la partition active depuis la table de partitions
- La partition active contient le code de chargement de l'O.S

Le MBR



Les types d'infections du MBR

- Remplacement du bootstrap (*Stoned*)
 - Déplacement de la table de partitions (fin du MBR ou espace libre du disque)
 - Insertion du code à la place du bootstrap
- Remplacement du MBR (*Azura 91*)
 - Pas de sauvegarde de la table de partitions (plus d'espace)
 - Chargement de la partition active par le virus
- Modification de la table de partition (*Starship*)
 - La table de partitions est parsée et modifiée
 - Chargement d'un secteur différent, où est situé le virus

Vecteur de propagation

- A l'époque, les programmes étaient distribués sous forme de disquette bootable
 - Pas vraiment d'OS
- On s'échangeait des programmes en recopiant des disquettes
- Les virus de boot :
 - Se chargeaient en mémoire au démarrage de l'ordinateur
 - Repéraient la routine du BIOS chargée d'écrire sur une disquette (int 13h)
 - **Détournaient** cette routine vers du code viral
 - Lorsque cette routine était appelée :
 - Écriture des données demandées
 - ... puis écriture du virus sur le MBR

Propagation des virus MBR

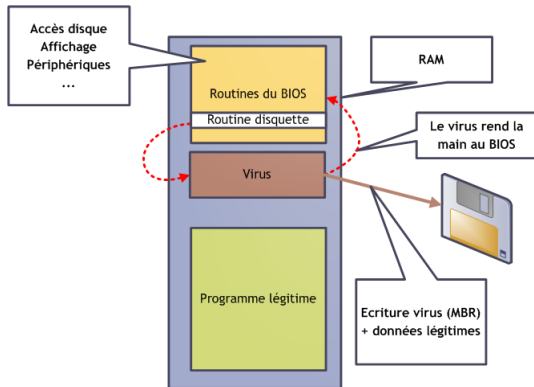


FIGURE: Propagation d'un virus type MBR

Plan

1 Introduction

2 Première génération : les virus de boot

- Méthode d'infection
- **Actualité**
- Détection

3 Deuxième génération : les infecteurs de fichier

4 Troisième génération : Chiffrement et polymorphisme

5 Conclusion

Et maintenant ?

Les virus Autorun sont les descendants actuels des virus de boot

- Sous Windows, lorsqu'un disque amovible est inséré, le fichier `autorun.inf` est examiné

Autorun

```
[autorun]
OPEN=virus.doc.exe
ICON=msword.ico
...
```

- Une fois le virus lancé, il scanner en permanence la présence de disques amovibles
 - Pour y ajouter `virus.exe` et `autorun.inf`
 - En fichier caché bien sûr
- Encore plus simple qu'avant !
- Et toujours aussi efficace ! (cf. *Seagate*)

Plan

1 Introduction

2 Première génération : les virus de boot

- Méthode d'infection
- Actualité
- Détection

3 Deuxième génération : les infecteurs de fichier

4 Troisième génération : Chiffrement et polymorphisme

5 Conclusion

Première génération : les scanners artisanaux

- Pas encore de société d'antivirus
- Souvent, un antivirus différent pour chaque virus
- Apparition de la recherche par signature

```

seg000:7C40 8E 04 00
seg000:7C40
seg000:7C43
seg000:7C43
seg000:7C43 next:
seg000:7C43 88 01 02
seg000:7C46 0E
seg000:7C47 07
seg000:7C48
seg000:7C48 88 00 02
seg000:7C48 33 C9
seg000:7C4D 8B D1
seg000:7C4F 41
seg000:7C50 9C
seg000:7C51 2E FF 1E 09 00
seg000:7C56 73 0E
seg000:7C58 33 C0
seg000:7C5A 9C
seg000:7C5B 2E FF 1E 09 00
seg000:7C60 4E
seg000:7C61 75 E0
seg000:7C63 EB 35

```

```

mov     si, 4           ; Try it 4 times
                        ;
                        ; CODE XREF: sub_7C3A+27↓j
mov     ax, 201h        ; read one sector
push    cs
pop     es
assume  es:seg000
mov     bx, 200h        ; to here
xor     cx, cx
mov     dx, cx
inc     cx
pushf
call    dword ptr cs:9   ; int 13
jnb     short fine
xor     ax, ax
pushf
call    dword ptr cs:9   ; int 13
dec     si
jnz     short next
jmp     short giveup

```

La recherche par signature

- Architecture de Von Neumann : code \simeq données
- Un programme binaire peut être vu comme un fichier quelconque
- Les premiers antivirus :
 - Lecture du MBR
 - Recherche d'une signature simple (on ne parle même pas de regexp)
 - Si signature trouvée \rightarrow alerte ou réparation du MBR
- Un antivirus ne ciblait qu'un ou deux virus
- Acceptable, car moins d'une dizaine de nouveaux virus par an

Plan

1 Introduction

2 Première génération : les virus de boot

3 Deuxième génération : les infecteurs de fichier

■ Fonctionnement

■ Les différents types d'infection

■ Détection

- Recherche par signature
- Heuristique

4 Troisième génération : Chiffrement et polymorphisme

Les infecteurs de fichiers

Les infecteurs de fichiers exécutables

- Même fonctionnement que les virus biologiques
- Virus informatiques les plus répandus
- De nombreuses cibles :
 - PE-exe, ELF, bat, sh, .py, .vbs
- De nombreuses méthodes d'infection :
 - appenders, prependers, cavity infectors, compagnons

Principe général

Les infecteurs de fichiers :

- Un exécutable est un fichier standard avec un format défini
 - Format PE : <http://www.microsoft.com/whdc/system/platform/firmware/PECOFF.mspx>
 - Format ELF : http://www.asm-x86.fr/le-format-elf_a8
- Il est tout à fait légal de créer/modifier un fichier exécutable
 - gcc, patch, ld
- Il est ainsi possible d'**ajouter** et de **modifier** le code d'un programme

Infection d'un exécutable

■ Comment infecter un fichier exécutable ?

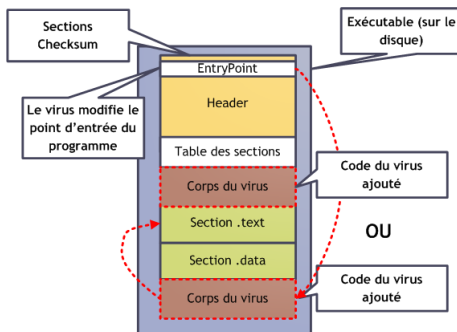


FIGURE: Infection d'un exécutable

Spécificités

- Le code du virus doit être *position independant*
 - Difficile de savoir où l'exécutable sera chargé (ASLR ...)
- Il faut modifier l'exécutable hôte pour y insérer le virus
 - Conserver la cohérence de la structure du fichier (checksum, en-têtes, ...)
- *Détournement* du flot de contrôle au sein de l'exécutable
 - Modification de l'EP, per process residency, etc.
- Plusieurs générations sur un même système hôte (proche du virus biologique)
 - Possibilité de *mutation* (polymorphisme, métamorphisme, ...)

Plan

1 Introduction

2 Première génération : les virus de boot

3 Deuxième génération : les infecteurs de fichier

■ Fonctionnement

■ Les différents types d'infection

■ Détection

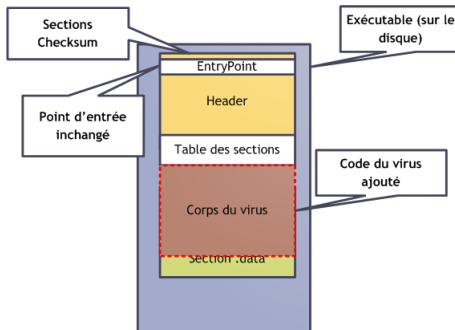
- Recherche par signature
- Heuristique

4 Troisième génération : Chiffrement et polymorphisme

Les virus parasites

Overwriting infectors

- Virus destructif
- Le corps du virus est écrit **sur** le fichier hôte
- Le virus, une fois exécuté, ne rendra pas la main
- Premiers infecteurs d'exes



Les virus parasites (2)

Avantages

- Extrêmement simples
 - Infecte tous types de fichiers
- Pas besoin de PIC
 - C'est une copie d'exécutable

Inconvénients

- Détectable par l'utilisateur
- Besoin de plus ?

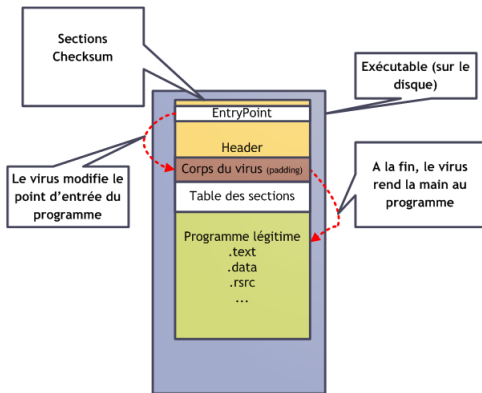
Exemple

Les premiers virus DOS

Les infecteurs de header

Header infectors

- Code du virus très court
- Inséré après les header de l'exécutable (padding)
- Modification du point d'entrée



Les infecteurs de header (2)

Avantages

- Pas de modification de la taille du fichier
 - Contre les whitelists
- Pas de création/modification des sections
 - Contre les heuristiques les plus grossières

Inconvénients

- Corps du virus nécessairement très court
- Pas toujours de padding (XP, Vista)

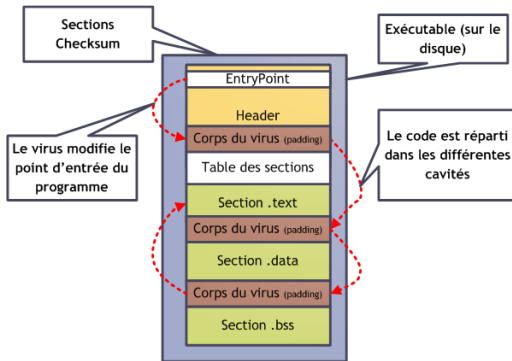
Exemple

Murky

Les infecteurs de cavité

Cavity infectors

- Code du virus assez court
- Fragmenté en N parties, liées entre elles par des `jmp`
- Inséré dans les sections *inutiles* (`.reloc`), dans le *padding*
- Modification du point d'entrée



Les infecteurs de cavité (2)

Avantages

- Pas de modification de la taille du fichier
 - Contre les whitelists
- Pas de création/modification des sections
 - Contre les heuristiques les plus grossières

Inconvénients

- Plus complexe (nécessite de reloger chaque partie)
- Plus de place que pour l'infection de header, mais reste court (- de 4k)

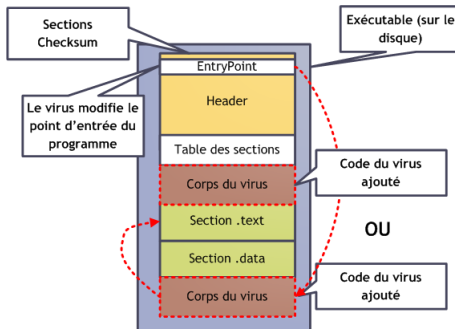
Exemple

CIH, W2K/Installer

Les infecteurs de fin/début de fichier

File infectors

- Code du virus arbitrairement long
- Inséré en début ou fin de fichier
- Modification de la table des sections
- Modification du point d'entrée



Les infecteurs de début de fichier

Infection en début de fichier

- Code du virus inséré **avant** la toute première section
- Décalage de toutes les sections suivantes
 - Nécessite les informations de relocation
 - Sauf si on utilise l'*imagebase trick*
- Plutôt discret (les heuristiques observent plus souvent la fin du fichier)

Les infecteurs de fin de fichier

Infection en fin de fichier

- Type d'infection le plus répandu
- Code du virus inséré **après** la dernière section
- Éventuellement, ajout d'une section supplémentaire
- Moins discret que l'insertion à la fin du fichier
 - ... mais plus simple

Les infecteurs de fin/début de fichier (2)

Avantages

- Portable
 - Quasiment tous les exécutables peuvent être infectés par cette méthode
- Simple à mettre en oeuvre
- Corps du virus arbitrairement long

Inconvénients

- Modification
 - de la taille du fichier
 - de la table des sections
 - de l'entrypoint
- Les antivirus regardent principalement la fin et le début des exécutables
- Virus en un seul bloc
 - signature plus aisée

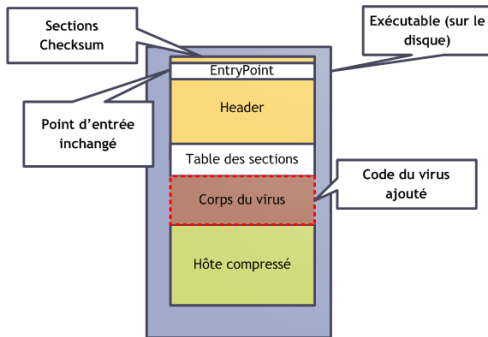
Exemple

Anxiety, 90% des virus

Les virus *compresseurs*

Compressing infectors

- Code du virus relativement court
- Inséré à la place du code de l'hôte
- L'hôte est compressé (ZIP, LFZ ...)
- ... et déplacé à la fin du fichier



Les virus *compresseurs* (2)

Avantages

- Pas de modification de la taille du fichier
 - Contre les whitelists
- Virus non-PIC
- Plus difficile à désinfecter

Inconvénients

- Plus complexe
- Code nécessairement plus petit
- Infection pas toujours possible

Exemple

W32/Redemption, W32/Aldebera

Démo

Démonstration

- Cible : Notepad
- Différences avant/après infection

Plan

1 Introduction

2 Première génération : les virus de boot

3 Deuxième génération : les infecteurs de fichier

- Fonctionnement
- Les différents types d'infection
- **Détection**
 - Recherche par signature
 - Heuristique

4 Troisième génération : Chiffrement et polymorphisme

La recherche par signature

- Scanner de première génération \simeq FSA
 - Code \Leftrightarrow données
 - Signature \Leftrightarrow expression régulière
- Permet une détection exacte
- Complexité ?
- Un antivirus actuel contient plus de 100000 signatures

La recherche par signature (2)

```

seg000:7C40 BE 04 00          mov     si, 4          ; Try it 4 times
seg000:7C40                  ;
seg000:7C43                  ;
seg000:7C43                  ; CODE XREF: sub_7C3A+27↓j
seg000:7C43 8B 01 02          next:      mov     ax, 201h      ; read one sector
seg000:7C46 0E                  push    cs
seg000:7C47 07                  pop     es
seg000:7C48                  assume es:seg000
seg000:7C48 8B 00 02          mov     bx, 200h      ; to here
seg000:7C4B 33 C9          xor     cx, cx
seg000:7C4D 8B D1          mov     dx, cx
seg000:7C4F 41          inc     cx
seg000:7C50 9C          pushf
seg000:7C51 2E FF 1E 09 00      call    dword ptr cs:9 ; int 13
seg000:7C56 73 0E          jnb     short fine
seg000:7C58 33 C0          xor     ax, ax
seg000:7C5A 9C          pushf
seg000:7C5B 2E FF 1E 09 00      call    dword ptr cs:9 ; int 13
seg000:7C60 4E          dec     si
seg000:7C61 75 E0          jnz     short next
seg000:7C63 EB 35          jmp     short giveup

```

FIGURE: Stone : entrypoint

Signature : 0400 B801 020E 07BB 0002 33C9 8BD1 419C

La recherche par signature (3)

Format des signatures

- Wildcards (joker) pour les virus **oligomorphiques**

Exemple

0400 B801 020E 07BB ? ? 02 %3 33C9 8BD1 419C

- Mismatches
 - mismatch de 2 \Leftrightarrow autorise une distance $j=2$ entre chaque lexème du pattern
- Bookmarks
 - Zone de code stratégique du virus (OEP, clé de chiffrement)
 - Généralement utilisé pour la désinfection

Optimisation de la recherche par signature

- Filtrage de fichiers
 - Ne considérer que les *.exe
- Signature hashing
 - Les X premiers octets de la signature sont hashés
- Recherche localisée (smart scanning)
 - En début, fin de fichier, à l'entrypoint
- Smart scanning
 - Ignorer les opcodes inutiles (nop, std ...)

L'heuristique

Vérification statique de la structure des exécutables :

- L'entrypoint est dans la dernière section ?
- La dernière section est exécutable ?
- Certains champs du header sont mal calculés ?
- Une section .reloc ou .data reçoit le flot d'exécution ?
- Transfert du flot d'exécution d'une section à une autre ?
- Apis suspectes importées (FindFistFile/FindNextFile/WriteFile ...)?

Heuristique

Exemple de sortie d'un moteur heuristique

Analyzing SGWW2202.VXE

- Execution starts **in** last section
 - Suspicious **code** section characteristics
 - Virtual **size** is incorrect **in** header
 - Suspicious relocation
 - Suspicious **code** section
 - Using KERNEL32 address directly **and** looking for PE00
- => Possibly infected with an unknown Win32 virus (Level: 9)

Plan

- 1 Introduction
- 2 Première génération : les virus de boot
- 3 Deuxième génération : les infecteurs de fichier
- 4 Troisième génération : Chiffrement et polymorphisme
 - Le chiffrement de code
 - La mutation de code
 - Détection
- 5 Conclusion

Principe

La mutation de code

- Technique de protection des virus
- Objectif : éviter la détection par les **scanners**
- Méthode : camoufler le code du virus
- Moyens :
 - Chiffrement
 - Oligomorphisme
 - Polymorphisme
 - Metamorphisme

Le chiffrement

- Technique simple : chiffrer le corps du virus
- Le code du virus commence par un petit décodeur **en clair**
 - Code constant
 - Clé embarquée, codée en dur
 - la clé **change à chaque génération**
- Une fois déchiffré, saut vers le corps du virus




FIGURE: Chiffrement de virus

Le chiffrement (2)

Décrypteur du virus Mad

```
mov edi, Start
add edi, ebp
mov ecx, 0A6Bh
mov a1, [Key]
Decrypt :
xor [edi], a1
inc edi
loop Decrypt
jmp Start
Start :
; code du virus
```

Le chiffrement (3)

Technique plus avancées :

- Le décodeur peut changer de position
- Les décodeurs peuvent s'enchaîner (layers)
- Utilisation d'API crypto
- Le décodeur bruteforce la clé (RDA fighter)

A votre avis

- Quelles contremesures possibles ?


Plan

- 1 Introduction
- 2 Première génération : les virus de boot
- 3 Deuxième génération : les infecteurs de fichier
- 4 Troisième génération : Chiffrement et polymorphisme
 - Le chiffrement de code
 - **La mutation de code**
 - Détection
- 5 Conclusion

L'oligomorphisme

Oligomorphisme

- Le décodeur reste en clair
- Utilisation de plusieurs décodeurs différents
 - Whale 12, Memorial 96
- Choix aléatoire d'un décodeur
- Chaque décodeur est écrit par le vxeur




A votre avis

- Quelles contremesures possibles ?

Le polymorphisme

Le polymorphisme

- Muter le code du décodeur à chaque génération
- Code différent mais fonctionnement équivalent
- Premier virus polymorphique : 1260 (1990)



Mutation de code

Quelques mutations possibles :

- Insertion de code mort
- Réorganisation (géographique) du code
- Mutations syntaxiques (cf. TP)
 - Utilisation de registres différents
 - Utilisation d'opcodes différents
- Modification du CFG
- ... et beaucoup d'autres

A Taxonomy of Obfuscating Transformations -
C.Collberg

Un décrypteur de 1260

```
inc     si           ; optional, variable junk
mov     ax,0E9B      ; set key 1
clc     ; optional, variable junk
mov     di,012A      ; offset of Start
nop     ; optional, variable junk
mov     cx,0571      ; this many bytes — key 2
; Group 2 Decryption Instructions
```

Decrypt:

```
xor     [di],cx       ; decrypt first word with key 2
sub     bx,dx         ; optional, variable junk
xor     bx,cx         ; optional, variable junk
sub     bx,ax         ; optional, variable junk
sub     bx,cx         ; optional, variable junk
nop     ; non—optional junk
xor     dx,cx         ; optional, variable junk
xor     [di],ax       ; decrypt first word with key 1
; Group 3 Decryption Instructions
inc     di           ; next byte
nop     ; non—optional junk
clc     ; optional, variable junk
inc     ax           ; slide key 1
; loop
loop    Decrypt      ; until all bytes are decrypted slide key 2
; random padding up to 39 bytes
Start:
;     Encrypted/decrypted virus body
```

Démo

Démonstration

■ Code source :

```
push 0xDEADBEEF
```

```
push 0xDEADBABE
```

■ Mutation du code


A votre avis

- Quelles contremesures possibles ?

Le metamorphisme

Le metamorphisme

- Plus de décodeur, trop "voyants"
- Polymorphisme de tout le virus
- Parfois metamorphisme de l'hôte
- Premier virus métamorphique : Regswap (1998)



Zmist

Zmist par Zombie (2000)

- Virus métamorphique
 - mutations syntaxiques
 - modification du CFG
- Intégration du virus dans l'hôte
 - Désassemblage de l'hôte
 - Relocation
 - Intégration du virus par îlots
- Recompilation du nouvel exécutable
- Détecté à 99,1% au bout de 7 ans

A votre avis

- Quelles contremesures possibles ?

Plan

- 1 Introduction
- 2 Première génération : les virus de boot
- 3 Deuxième génération : les infecteurs de fichier
- 4 Troisième génération : Chiffrement et polymorphisme
 - Le chiffrement de code
 - La mutation de code
 - Détection
- 5 Conclusion

Le problème de détection

- Virus chiffrés simples ou oligomorphiques \Rightarrow détection par signature sur le décodeur
 - Au plus, N signatures nécessaires
- Technique *X-Ray*
 - Cryptanalyse automatisée pour les chiffrement les plus simples
 - Détection du **corps** du virus
- Heuristique
- Virus polymorphiques **simples** \Rightarrow détection par signatures

Le problème de détection (2)

- Virus poly/métamorphiques complexes ?
 - Une infinité de décodeurs peut être générée
 - On parle du **langage** du moteur de poly/métamorphisme
 - Symboles terminaux \Leftrightarrow instructions machines
- **Détection** du virus \simeq **reconnaissance de ce langage**
- Quelle complexité ?
- Un peu de théorie ...

Hierarchie des langages formels




FIGURE: Langages formels

Hierarchie des langages et complexité

Chomsky level	Grammaire	Langage	Autom. min.	Complexité
Type 0	Unrestricted	Recursively enumerable	Turing machine ¹	-
-	-	Recursive	Decider	?
Type 1	Contexte-sensitive	Contexte sensitive	Linear bounded TM	?
-	Tree adjoining	Middly context-sensitive	Embedded pushdown	P
Type 2	Context-free	Context-free	Nondet. pushdown	?
-	$LL(k)$ ²	$LL(k)$	Det. lookahead pushdown	?
-	Det. context-free	Det. context-free	Det. pushdown	?
Type 3	Regular	Regular	DFA	?
-	-	Star-free	Aperiodic finite	?

- `mov reg,cst ⇒ nop ; mov reg,cst ?`
- `mov reg,cst ⇒ push reg2 ; mov reg2,cst ; mov reg,reg2 ; pop reg2 ?`

-
1. qui peut ne pas s'arrêter
 2. et $LR(k)$...

Le problème de détection (3)

- Le problème de détection général est **indécidable**, que faire ?
- Heuristique
- Une détection exacte n'est pas obligatoire
 - Détection de séquences d'instructions **suspectes** (signature)
- Analyse statistique des instructions

Scan antivir

```
C:\taf\cours\09-10\lp\secu\cours\virus\demo1\testnotepad.exe  
[RESULTAT] Contient le code suspect : GEN/Malware  
[REMARQUE] Le résultat positif a été classé comme suspect.
```


L'émulation

- Pour les virus polymorphiques, le corps du virus **déchiffré** reste constant
- Idée : **Emuler** le décodeur du virus
 - Interprétation du code machine instruction par instruction
 - Arrêt de l'émulateur à la fin du décodage
- Le corps du virus apparaît en clair dans la VM de l'antivirus
- \Rightarrow signature sur le corps du virus

L'émulation(2)

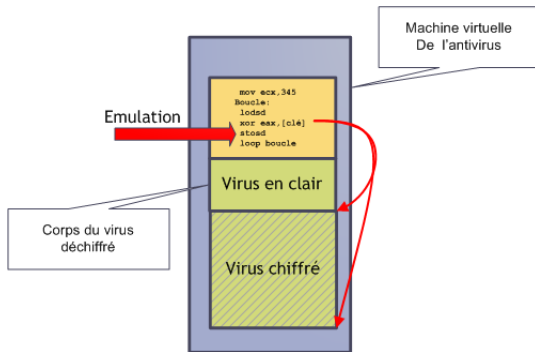


FIGURE: Emulation du décodeur du virus

L'émulation : problèmes et solutions

- Emuler du code est **lent** (et **non décidable**)
- Les virus tirent profit de cette lenteur :
 - Insertion de code inutile long à émuler
 - Insertion d'instructions non supportées par l'émulateur
- Contre-mesures :
 - Suppression du code mort
 - Exécution des boucles **inoffensives** en **natif** (*code normalization*)

La détection comportementale

- Virus métamorphiques complexes : que faire ?
- L'antivirus détourne les principaux appels systèmes
- A l'**exécution** d'un programme, la séquence d'appels système est vérifiée
 - Détection de sous-séquence d'appels systèmes suspects (FindFirstFile(*.exe), WriteFile ...)
 - Détection de fréquences d'appels systèmes suspects
- Avantage : très efficace contre les vers/trojans (API réseau)
- Inconvénients :
 - Ralentit le système de l'utilisateur
 - Détection parfois trop tardive

Détection comportementale

Malware behaviour analysis *Wagener, G. and State, R. and Dulaunoy, A. - 2008*

Etat de l'art

Etat de l'art :

- Signature + heuristique + émulation
- Heuristique au sein de l'émulateur
 - Détection d'accès séquentiel au code du programme
 - Détection de routines virales classiques (scan *.exe, etc.)
 - Code auto-modifiant
- Sandboxing (expérimental) : émulation de l'os en entier
- la majorité des virus sont détectés sans mise à jour de l'antivirus

Plan

- 1 Introduction
- 2 Première génération : les virus de boot
- 3 Deuxième génération : les infecteurs de fichier
- 4 Troisième génération : Chiffrement et polymorphisme
- 5 Conclusion
 - Actuellement
 - Perspectives

Actuellement

- L'augmentation de la fréquence des CPU joue en faveur des antivirus
 - Capacité d'émulation augmentée
- L'augmentation de la taille des disques et du débit réseau joue en faveur des virus
 - Plus complexes
- Néanmoins :
 - Les virus restent majoritairement détectés dès leur sortie
 - Très peu de virus innovants actuellement
 - Arrestations massives il y a 4-5 ans (29A)

Plan

- 1 Introduction
- 2 Première génération : les virus de boot
- 3 Deuxième génération : les infecteurs de fichier
- 4 Troisième génération : Chiffrement et polymorphisme
- 5 Conclusion
 - Actuellement
 - Perspectives

Changement sociologiques

- Presque plus de vxers hobbyistes
- La mode est au **profit**
 - Equipe de plusieurs programmeurs
 - Réutilisation des techniques de virologie
 - Ajout de propagation via le réseau (mix virus/vers/botnets)
- Une faille = un vers lancé sous deux semaines
- Objectif : spam \Rightarrow profit

La rentabilité des botnets

Spamalytics : An Empirical Analysis of Spam Marketing Conversion

<http://www.icsi.berkeley.edu/pubs/networking/2008-ccs-spamalytics.pdf>

Récapitulatif

Attaque	Défense
Virus boot	Signature
Infecteur de fichier	Signature, heuristique
Polymorphisme	Émulation+Signature, heuristique
Metamorphisme	Détection comportementale, heuristique
Vers, chevaux de troie	Détection comportementale, signature

- La **quasi totalité des techniques** des rootkits, vers, trojans et shellcodes **sont issues des virus**